Büyük Veri Yaklaşımıyla Öğrenci Akademik Performansının Analizi ve Ölçeklenebilirlik İncelemesi

I. GİRİŞ

Bu projenin amacı öğrenci akademik performansıyla ilişkili faktörleri Apache Spark kullanarak büyük veri yaklaşımıyla analiz etmektir. Bu çalışmada kullanılan *Student Academic Performance* veri seti çoğaltma (replication) yöntemiyle ölçeklendirilmiş ve öğrencilerin akademik başarıları GPA üzerinden incelenmiştir. Derse devam oranı, çalışma süresi, uyku düzeni ve sosyal medya kullanımı gibi değişkenlerin akademik başarı ile olan ilişkileri analiz edilmiştir.

I.1. Araştırma Soruları

1. Derse devam oranı yüksek ancak günlük çalışma süresi düşük olan öğrencilerde uyku süresi ile akademik başarı (GPA) arasında nasıl bir ilişki vardır?
2. Sosyal medya kullanım süresi ile akademik başarı (GPA) arasında bir ilişki var mıdır?
3. Günlük çalışma süresi yüksek olmasına rağmen akademik başarısı (GPA) düşük olan öğrencilerde stres düzeyi ve uyku süresi ile akademik başarı arasında nasıl bir ilişki vardır?

Araştırma soruları arasından bu çalışmada incelenmek üzere 1. soru seçilmiştir.

II. BÜYÜK VERİ YAKLAŞIMI VE SPARK KULLANIMI

II.1. Apache Spark Ortamı ve Kullanım Gerekçesi

Bu çalışmada Apache Spark'ın Python tabanlı arayüzü olan PySpark kullanılmıştır. Veri seti Spark DataFrame yapısında işlenmiş ve tüm analizler Spark'ın bellek içi hesaplama yeteneklerinden yararlanılarak gerçekleştirilmiştir. Apache Spark, büyük ölçekli verilerin hızlı ve ölçeklenebilir biçimde işlenmesini sağlayan bir büyük veri platformudur ve bu özellikleri sayesinde geleneksel veri analiz araçlarına kıyasla yüksek hacimli veri işlemlerinde önemli performans avantajları sunmaktadır. Bu çalışmanın amacı yalnızca istatistiksel sonuçlar elde etmek değil, analizi büyük veri yaklaşımıyla gerçekleştirmektir. Bu doğrultuda veri seti 100.000 satıra ölçeklendirilmiş; tanımlayıcı istatistikler, korelasyon analizi ve kümeleme işlemleri Spark tabanlı ölçeklenebilir veri işleme yaklaşımıyla yürütülmüştür.

II.2. Veri Ölçekleme Yöntemi

Projede kullanılan orijinal veri seti 250 öğrenci kaydından oluşmaktadır ancak Apache Spark'ın temel kullanım amacı büyük hacimli verilerin işlenmesidir. Bu nedenle veri seti Spark ortamında ölçeklendirilmiştir. Ölçekleme sürecinde veri setine yeni sentetik veri eklenmemiş, rastgelelik veya gürültü uygulanmamış ve mevcut değerler değiştirilmemiştir. Bunun yerine veri setindeki mevcut gözlemler Spark üzerinde çoğaltma (replication) yöntemiyle tekrar edilerek satır sayısı 100.000'e çıkarılmıştır. Bu yaklaşım sayesinde veri setinin istatistiksel

dağılımı korunmuş, yalnızca veri sayısı artırılmıştır. Ölçeklendirilmiş 100.000 kayıt, 250 orijinal öğrenci gözleminin tekrarlarından oluşmakta olup yeni veya benzersiz öğrenci verisi üretmemektedir.

III. TANIMLAYICI İSTATİSTİKLER

Bu bölümde Korelasyon Analizi ve Kümeleme kısımlarına geçmeden önce veri setinin genel yapısını ve öğrencilerin genel özelliklerini anlamak amacıyla tanımlayıcı istatistikler kullanılmıştır. Tanımlayıcı istatistikler, herhangi bir karşılaştırma yapmadan önce verinin genel yapısını ve nasıl bir dağılım gösterdiğini anlamamızı sağlar. Bu amaçla çalışmada ortalama, standart sapma, medyan ve çeyrek değerler kullanılmıştır. Bu istatistikler tüm sayısal değişkenler için hesaplanmış ancak yorumlar araştırma sorularıyla doğrudan ilişkili olan değişkenler için yapılmıştır. Bu kapsamda; akademik başarı (GPA), derse devam oranı, günlük çalışma süresi, uyku süresi, stres düzeyi ve sosyal medya kullanım süresi değişkenleri seçilmiştir.

Değişken	Ortalama	Std. Sapma	Min	Q1 (25%)	Medyan	Q3 (75%)	Max
GPA	7.29	0.93	5.00	6.69	7.28	7.97	9.51
Attendance_%	85.80	9.36	57.9	80.2	85.8	93.4	100
Study_Hours_per_Day	5.03	1.59	0.0	4.0	5.1	6.0	8.0
Sleep_Hours	7.04	1.18	4.0	6.3	7.1	7.9	9.0
Stress_Level_(1–10)	5.21	1.99	1.0	3.6	5.3	6.6	10
Social_Media_Hours	3.09	1.45	0.0	2.0	3.2	4.0	6.6
Midterm_Score	69.74	14.52	30.0	59.4	69.8	80.1	100
Final_Score	74.92	12.09	41.3	67.7	73.6	83.8	100

Elde edilen sonuçlara göre öğrencilerin akademik başarısını temsil eden GPA değişkeninin ortalama değeri 7.29 olup bu değer öğrencilerin genel başarı düzeyinin orta–yüksek seviyede olduğunu göstermektedir. Derse devam oranının ortalama %85.80 olması öğrencilerin büyük çoğunluğunun derslere düzenli olarak katıldığını ortaya koymaktadır. Günlük çalışma süresinin ortalama 5.03 saat uyku süresinin ise ortalama 7.04 saat olması öğrencilerin çalışma ve yaşam düzenlerinin genel olarak dengeli bir yapıya sahip olduğunu göstermektedir. GPA için ortalama ve medyan değerlerin birbirine yakın olması (7.29–7.28) ve çeyrek değerlerin dar bir aralıkta toplanması akademik başarı dağılımının dengeli olduğunu ve uç değerlerin baskın olmadığını göstermektedir. Elde edilen bu tanımlayıcı istatistikler veri setinin genel yapısını ortaya koymuş ve sonraki korelasyon analizi ile kümeleme çalışmalarına hazırlık oluşturmuştur.

IV. KORELASYON ANALİZİ



Bu grafikte öğrencilerin akademik başarısı (GPA) ile veri setinde yer alan diğer sayısal değişkenler arasındaki Pearson korelasyonları ısı haritası (heatmap) biçiminde sunulmuştur. En güçlü pozitif ilişkiler Final_Score ile GPA arasında (r = 0.77) ve Midterm_Score ile GPA arasında (r = 0.59) görülmektedir. Buna karşılık sosyal medya kullanım süresi, derse devam oranı, günlük çalışma süresi ve uyku süresi GPA ile sıfıra yakın veya oldukça zayıf ilişkiler göstermektedir. Stress_Level değişkeni ise GPA ile zayıf düzeyde negatif bir ilişkiye sahiptir (r = -0.18). Genel olarak korelasyon matrisi, bu veri setinde GPA ile en güçlü doğrusal ilişkilerin sınav notlarında görüldüğünü ortaya koymaktadır.

Seçilen araştırma sorusu açısından genel korelasyon matrisi incelendiğinde derse devam oranı ile GPA arasında çok zayıf düzeyde pozitif, uyku süresi ile GPA arasında ise sıfıra yakın bir ilişki görülmektedir. Bu sonuçlar, derse devam ve uyku süresi değişkenlerinin GPA ile tek başına güçlü bir doğrusal ilişki göstermediğini ortaya koymaktadır. Araştırma sorusu, korelasyon sonuçlarının yanı sıra devam, uyku ve günlük çalışma süresini birlikte değerlendiren K-Means profilleri üzerinden de incelenmiştir.

V. ÖĞRENCİ PROFİLİ OLUŞTURMA (KÜMELEME ANALİZİ)

Bu çalışmada öğrencileri benzer davranışsal özelliklerine göre gruplandırmak amacıyla K-Means kümeleme algoritması kullanılmıştır. Kümeleme sürecinde öğrencilerin derse devam oranı (Attendance_%), günlük çalışma süresi (Study_Hours_per_Day) ve uyku süresi (Sleep_Hours) değişkenleri dikkate alınmıştır. Akademik başarıyı temsil eden GPA değişkeni kümelerin doğrudan başarı düzeyine göre oluşmasını engellemek ve öğrencilerin davranışsal özelliklerine dayalı profiller elde edebilmek amacıyla kümeleme aşamasına dahil edilmemiştir. GPA değeri, kümeleme sonrasında profillerin akademik başarı düzeylerinin yorumlanmasında kullanılmıştır.

Küme	Kayıt Sayısı	Ortalama Derse Devam (%)	Ortalama Uyku Süresi (saat)	Ortalama Günlük Çalışma (saat)	Ortalama GPA
Küme 0	36400	78.14	6.19	5.09	7.29
Küme 1	28400	87.55	7.81	3.57	7.26
Küme 2	35200	92.29	7.30	6.15	7.33

Kümeleme analizi sonucunda veri seti üç farklı kümeye (k = 3) ayrılmıştır. Ölçeklendirilmiş veri setinde kümelere ait kayıt sayıları sırasıyla 36.400, 28.400 ve 35.200 olarak elde edilmiştir. Bu dağılım, her kümenin veri seti içerisinde anlamlı bir büyüklüğe sahip olduğunu ve kümeleme sonucunun dengeli bir yapı sunduğunu göstermektedir.

Kümeleme analizinde öğrencileri derse devam, günlük çalışma süresi ve uyku alışkanlıkları açısından yorumlanabilir davranışsal profillere ayırmak amacıyla küme sayısı k = 3 olarak belirlenmiştir. Bu seçim sonucunda söz konusu değişkenler bakımından birbirinden farklı üç öğrenci profili elde edilmiştir.

Profil Adı	Küme	Kayıt Sayısı	Davranışsal Özellikler	Yorum
Profil 1 – Düşük Katılım ve Düzensiz Yaşam	Küme 0	36.400	**Derse Devam**:%78.1; **Uyku**: 6.2 saat; **Günlük Çalışma**: 5.1 saat; **GPA**: 7.29	Bu profil; düşük derse devam oranı, kısa uyku süresi ve orta düzey günlük çalışma süresiyle karakterizedir. Ortalama GPA değeri 7.29'dur.
Profil 2 – Düzenli Yaşam, Az Çalışan	Küme 1	28.400	**Derse Devam**:%87.6; **Uyku**: 7.8 saat; **Günlük Çalışma**: 3.6 saat; **GPA**: 7.26	Bu profil; görece yüksek derse devam oranı, en yüksek ortalama uyku süresi ve en düşük günlük çalışma süresiyle karakterizedir. Ortalama GPA değeri 7.26'dır.
Profil 3 – Dengeli ve Çok Çalışan	Küme 2	35.200	**Derse Devam**:%92.3; **Uyku**: 7.3 saat; **Günlük Çalışma**: 6.1 saat; **GPA**: 7.33	Bu profil, en yüksek ortalama derse devam oranına ve günlük çalışma süresine sahiptir. Ortalama GPA değeri 7.33 ile üç profil içinde sınırlı farkla en yüksektir.

Profil 1 – Düşük Katılım ve Düzensiz Yaşam Profili (Küme 0)
Bu profil, ortalama %78.1 derse devam oranı, 6.2 saat uyku ve 5.1 saat günlük çalışma süresiyle üç profil arasında en düşük devam ve uyku değerlerine sahiptir. Ortalama GPA değeri 7.29'dur. Sonuçlar, bu davranışsal özelliklerin aynı profil içerisinde birlikte gözlendiğini göstermekte olup değişkenler arasında doğrudan bir neden–sonuç ilişkisi kurmamaktadır.

Profil 2 – Düzenli Yaşam, Az Çalışan Profili (Küme 1)
Bu profil, ortalama %87.6 derse devam oranı, 7.8 saat uyku ve 3.6 saat günlük çalışma süresiyle araştırma sorusuna en yakın grubu temsil etmektedir. Üç profil içerisinde günlük çalışma süresi en düşük, uyku süresi ise en yüksek olan gruptur. Ortalama GPA değeri 7.26'dır. Bu sonuç, yüksek devam ve uzun uyku süresinin bu profilde daha yüksek bir GPA ortalamasıyla birlikte görülmediğini göstermektedir.

Profil 3 – Dengeli ve Çok Çalışan Profili (Küme 2)
Bu profil, ortalama %92.3 derse devam oranı, 7.3 saat uyku ve 6.1 saat günlük çalışma süresiyle üç profil arasında en yüksek devam ve çalışma değerlerine sahiptir. Ortalama GPA değeri 7.33 ile diğer profillerden sınırlı ölçüde daha yüksektir. Bu sonuç, devam, uyku ve çalışma süresi değişkenlerinin birlikte ele alındığı farklı bir davranışsal profili ortaya koymaktadır.

VI. SONUÇ

VI.1 Genel Sonuç

Bu çalışmada, öğrenci akademik performansıyla ilişkili faktörler büyük veri yaklaşımıyla incelenmiştir. Başlangıçta 250 satırdan oluşan veri seti Apache Spark ortamında ölçeklenerek 100.000 gözleme çıkarılmış ve Spark'ın büyük veri işleme kabiliyeti pratik olarak test edilmiştir. Bu sayede Apache Spark'ın veri işleme ve ölçeklenebilirlik yaklaşımı daha yüksek veri hacmi üzerinde uygulanmıştır.

Elde edilen bulgular, akademik başarının (GPA) tek bir değişkenle açıklanamayacağını göstermektedir. Özellikle korelasyon analizinde, GPA ile en güçlü ilişkilerin final ve vize sınav notlarıyla ortaya çıktığı görülmüştür. Buna karşılık günlük çalışma süresi, derse devam oranı ve uyku süresi gibi değişkenlerin GPA ile doğrudan ve güçlü bir ilişki göstermediği belirlenmiştir. Bu durum, bu veri setinde GPA'nın günlük çalışma süresinden çok sınav notlarıyla daha güçlü bir doğrusal ilişki gösterdiğini ortaya koymaktadır.

Analiz sonuçları üç temel bulguyu öne çıkarmaktadır. İlk olarak Pearson korelasyon analizinde GPA ile en güçlü ilişkiler Final_Score ($r = 0.77$) ve Midterm_Score ($r = 0.59$) değişkenlerinde görülmüştür. Günlük çalışma süresi, derse devam oranı ve uyku süresi ise GPA ile güçlü doğrusal ilişkiler göstermemiştir. İkinci olarak K-Means analizi, derse devam, uyku ve günlük çalışma süresi bakımından üç farklı davranışsal profil oluşturmuştur. Üçüncü olarak bu profillerin GPA ortalamaları birbirine yakın olmakla birlikte, en yüksek devam ve günlük çalışma değerlerine sahip Profil 3'te GPA ortalaması 7.33 ile diğer profillerden sınırlı ölçüde daha yüksek bulunmuştur.

VI.2 Araştırma Sorusuna Yönelik Genel Sonuç

Seçilen araştırma sorusu bağlamında genel korelasyon sonuçları, uyku süresi ve derse devam oranının GPA ile güçlü doğrusal ilişkiler göstermediğini ortaya koymuştur. K-Means analizi ise derse devam, uyku ve günlük çalışma süresine göre üç davranışsal profil oluşturmuştur. Günlük çalışma süresi en düşük olan Profil 2'nin GPA ortalaması 7.26 iken, en yüksek çalışma ve devam değerlerine sahip Profil 3'ün GPA ortalaması 7.33 olarak elde edilmiştir. Profiller arasındaki GPA farklarının sınırlı olması, bu değişkenlerin tek başına akademik başarıyı açıklamak için yeterli olmadığını ve birlikte değerlendirilmesi gerektiğini göstermektedir.

VII. KODLAR VE AÇIKLAMALARI

Bu kısımda projenin kod kısmını bloklara böldüm ve kısaca ne yaptıklarını anlattım.

BLOK 1 — Kurulum ve ortam ayarı

```
!apt-get -qq install openjdk-17-jdk-headless > /dev/null
!pip -q install pyspark

import os
os.environ["JAVA_HOME"] = "/usr/lib/jvm/java-17-openjdk-amd64"
```

-PySpark'ın çalışabilmesi için gerekli olan Java ve PySpark kurulmuştur.

BLOK 2 — Spark oturumu başlatma

```
from pyspark.sql import SparkSession
from pyspark.sql import functions as F
from google.colab import files

spark = (
    SparkSession.builder
    .appName("StudentAcademicPerformance")
    .config("spark.sql.crossJoin.enabled", "true")
    .getOrCreate()
)
```

-SparkSession oluşturularak PySpark oturumu başlatılmıştır.

BLOK 3 — Dosya yükleme ve CSV'yi okuma

```
uploaded = files.upload()

csv_path = "/content/student_academic_performance.csv"
df = (
    spark.read
    .option("header", True)
    .option("inferSchema", True)
    .csv(csv_path)
)

df.printSchema()
df.show(5, truncate=False)
print("Satır sayısı:", df.count())
```

-CSV dosyası Colab'a yüklenmiş ve Spark DataFrame formatında okunmuştur. Şema (kolon tipleri), örnek 5 satır ve toplam satır sayısı kontrol edilmiştir.

BLOK 4 — Veri setini 100.000 satıra ölçekleme (replication)

```
base_count = df.count()
target_n = 100000
repeat_factor = (target_n + base_count - 1) // base_count

df_big = spark.range(repeat_factor).crossJoin(df).drop("id").limit(target_n)
print("Ölçeklenmiş satır sayısı:", df_big.count())
```

-Küçük veri seti (250 satır) Spark ortamında çoğaltma (replication) yöntemiyle 100.000 satıra çıkarılmıştır. Bu işlem yeni veri üretmez; mevcut kayıtları tekrar ederek yalnızca veri hacmini büyütür.

BLOK 5 — Tanımlayıcı istatistikler

```
desc_cols = [
    "GPA", "Attendance_%", "Study_Hours_per_Day", "Sleep_Hours",
    "Stress_Level_(1-10)", "Social_Media_Hours",
    "Assignments_Completed_%", "Midterm_Score", "Final_Score", "Age"
]

print("\nTABLO 1: DESCRIBE (count / mean / stddev / min / max)\n")
df_big.select(desc_cols).describe().show()
```

-Seçilen sayısal değişkenler için temel tanımlayıcı istatistikler (count, ortalama, standart sapma, minimum, maksimum) hesaplanmıştır.

BLOK 6 — Tanımlayıcı istatistikler-2

```
print("\nTABLO 2: QUARTILES (Q1=25%, Median=50%, Q3=75%)\n")
df_big.select(desc_cols).summary("25%", "50%", "75%").show()
```

-Çeyrek değerler ve medyan hesaplanmıştır.

BLOK 7 — GPA ile diğer değişkenler arasındaki korelasyonlar

```
corr_targets = [
    "Age",
    "Study_Hours_per_Day",
    "Sleep_Hours",
    "Attendance_%",
    "Assignments_Completed_%",
    "Midterm_Score",
    "Final_Score",
    "Stress_Level_(1-10)",
    "Social_Media_Hours"
]
```

```
corr_rows = [(c, df_big.stat.corr("GPA", c)) for c in corr_targets]
corr_df = (
    spark.createDataFrame(corr_rows, ["Variable", "Corr_with_GPA"])
    .orderBy(F.abs(F.col("Corr_with_GPA")).desc())
)

print("\nGPA ile diğer değişkenler arasındaki korelasyonlar (Pearson)\n")
corr_df.show(truncate=False)
```

-Akademik başarıyı temsil eden GPA ile diğer sayısal değişkenler arasındaki Pearson korelasyon katsayıları hesaplanmış ve mutlak değere göre sıralanmıştır.

BLOK 8 — Korelasyon matrisi ve heatmap görselleştirme

```
from pyspark.ml.feature import VectorAssembler
from pyspark.ml.stat import Correlation

matrix_cols = ["GPA"] + corr_targets
assembler = VectorAssembler(inputCols=matrix_cols, outputCol="features")
vec_df = assembler.transform(df_big.select(matrix_cols)).select("features")

corr_matrix = Correlation.corr(vec_df, "features", "pearson").head()[0]
corr_array = corr_matrix.toArray()

import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

corr_pd = pd.DataFrame(corr_array, columns=matrix_cols, index=matrix_cols)

plt.figure(figsize=(10, 8))
sns.heatmap(corr_pd, annot=True, fmt=".2f", cmap="coolwarm", center=0)
plt.title("Korelasyon Matrisi (Pearson)")
plt.tight_layout()
plt.show()
```

-Tüm sayısal değişkenler için korelasyon matrisi çıkarılmış ve sonuçlar ısı haritası (heatmap) ile görselleştirilmiştir.

BLOK 9 — K-Means kümeleme ile öğrenci profilleri (k=3)

```
from pyspark.ml.feature import StandardScaler
from pyspark.ml.clustering import KMeans

cluster_features = ["Attendance_%", "Sleep_Hours", "Study_Hours_per_Day"]
```

```
assembler_k = VectorAssembler(inputCols=cluster_features, outputCol="features")
tmp = assembler_k.transform(df_big.select(cluster_features + ["GPA"]))

scaler = StandardScaler(
    inputCol="features",
    outputCol="scaled_features",
    withMean=True,
    withStd=True
)
scaled = scaler.fit(tmp).transform(tmp)

kmeans = KMeans(k=3, seed=42, featuresCol="scaled_features")
model = kmeans.fit(scaled)

clustered = model.transform(scaled).withColumnRenamed("prediction", "cluster")
```

-Öğrenciler; derse devam, uyku süresi ve günlük çalışma süresi değişkenleri kullanılarak K-Means algoritması ile 3 kümeye ayrılmıştır.

BLOK 10 — Küme dağılımı ve profil ortalamaları

```
print("\nKÜME DAĞILIMI\n")
clustered.groupBy("cluster").count().orderBy("cluster").show()

print("\nKÜME PROFİL ÖZETİ (Ortalamalar)\n")
(
    clustered.groupBy("cluster")
    .agg(
        F.avg("Attendance_%").alias("avg_Attendance"),
        F.avg("Sleep_Hours").alias("avg_Sleep"),
        F.avg("Study_Hours_per_Day").alias("avg_StudyHours"),
        F.avg("GPA").alias("avg_GPA"),
    )
    .orderBy("cluster")
    .show(truncate=False) )
```

-Her kümedeki kayıt sayısı gösterilmiş ve her kümenin ortalama devam, uyku, çalışma süresi ve GPA değerleri hesaplanmıştır.